

Weekly Report May 22-25, 2026

張 辰強†

† 大阪大学大学院情報科学研究科

E-mail: †chenqiang.zhang@ist.osaka-u.ac.jp

1. 先週の確認待ち事項

What is the Watermarking in CTT. [1] 論文におけるウォーターマーク検出は、文章生成後に特徴を探す方法ではなく、LLM が文章を生成する過程で、提供者側が秘密の規則に基づいて語彙選択に隠れた統計的信号を埋め込む方法である。具体的には、候補語の中から特定の語、特に名詞・動詞・形容詞などの高エントロピー語を選びやすくする。検出時には、これらの語が通常より多く出現しているかを調べることで、その文章がウォーターマーク付きの AI 生成文である可能性を判断する。

What is the enhanced Turing? [8]Enhanced Test は、二つのチャット画面で tester が人間と AI を同時に比較しながら判断する、三つの役割・長時間対話・報酬・品質管理を備えた、より厳密なチューリングテスト環境である。

2. Does any prior research in NLP align with this proposal?




図 1 Turing Test with translations.

2.1 Explanation of the Proposal

Architecture of the MMTT (MT-Mediated Turing Test). A witness (human or AI) converses in language A (maybe the witness's native language), while a judge interrogates in real time using language B (maybe the interrogators' native language). **It is not necessary for the interrogators to be proficient in Language A.** The two interact through a bidirectional machine-translation channel. Under identity-blind conditions, the judge decides whether the witness is human or AI based solely on the translated output.

This design promotes translations from a post-processing tool to an integral part of the test channel, **examining whether the humanness signal can survive the bidirectional MT bottleneck.**

2.2 Related Work

近年、本研究テーマに近い研究はいくつか存在している。しかし、「Translated Turing Test (TTT)」を直接扱った代表的な研究は、現時点ではまだ多くない。

- (1) **GPT と Turing Test に関する研究:** 近年、GPT がチューリングテストを通過できるかを検証する研究が行われている。例えば Jones and Bergen は、オンラインのテキスト対話型チューリングテストにおいて GPT-4 の性能を評価した [4, 5, 9, 10]。その結果、GPT-4 は特定のプロンプト条件下で人間と判断される割合が高く、判定者は主に言語スタイルや社会的・感情的特徴を手がかりにしていた。これは、AI と人間を区別するうえで「言語スタイル」が重要であることを示している。
- (2) **Translation Turing Test に関する研究:** MT が人間翻訳に近いかを調べるために、Translation Turing Test を用いた研究もある。例えば Popel らの研究では、参加者に翻訳文が機械翻訳か人間翻訳かを判断させた [2, 7]。その結果、高品質な機械翻訳と人間翻訳を正確に区別することは難しいことが示された。
- (3) **LLM 翻訳と人間翻訳の比較:** 近年では、大規模言語モデルが人間の翻訳戦略を模倣できるかを調べる研究もある。He らの研究では、LLM が単なる言語変換ではなく、人間翻訳者のような多段階の翻訳方略を取れるかが検討されている [3]。
- (4) **Translationese / 翻訳調の検出研究:** LLM の翻訳文に「翻訳調」が残るかを分析する研究も行われている。例えば ACL 2025 の研究では [6]、LLM は大量の自然言語データで事前学習されていても、過度に直訳的で不自然な翻訳を生成する場合があると指摘されている。このような研究は、翻訳によって AI と人間の言語的特徴がどのように変化するかを分析するための基礎になる。

既存研究は主に、「人間は AI を識別できるか」と「人間は機械翻訳を識別できるか」の問題を扱っている。

3. Transforming machine translation: a deep learning system reaches news translation quality comparable to human professionals [7]

3.1 何を行ったのか

This paper proposes and evaluates a neural machine translation system called **CUBBITT** (Charles University **B**lock-**B**acktranslation-**I**mproved Transformer Translation). The main goal of the study is to examine how close deep-learning-based machine translation can come to professional human translation and whether it can surpass human translation in certain aspects.




図 2 What is the backtranslation

- (1) **CUBBITT**: Transformer を基盤とし、**block back-translation** や **checkpoint averaging** などの訓練方法を組み合わせて CUBBITT を構築した。これにより、単なる普通の Transformer 翻訳モデルではなく、実データと合成データをより効果的に利用する翻訳システムを作った。
- (2) 評価方法: **BLEU** は、機械翻訳の出力と人間による参照訳を比較し、1-gram から 4-gram までの一致度と長さのペナルティに基づいて翻訳品質を数値化する指標である;
- (3) **Translation Turing Test**: 参加者に訳文を見せて、それが人間による翻訳か機械翻訳かを判断させる実験である。結果として、Google Translate(SMT) の訳文は多くの参加者に識別されたが、CUBBITT の訳文は多くの参加者が人間翻訳と区別できなかった。

- [1] Megha Chakraborty, SM Towhidul Islam Tonmoy, SM Mehedi Zaman, Shreya Gautam, Tanay Kumar, Krish Sharma, Niyar Barman, Chandan Gupta, Vinija Jain, Aman Chadha, et al. Counter turing test (ct2): Ai-generated text detection is not as easy as you may think-introducing ai detectability index (adi). In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 2206–2239, 2023.
- [2] Mălina Chichirău, Rik Van Noord, and Antonio Toral. Automatic discrimination of human and neural machine translation in multilingual scenarios. In *Proceedings of the 24th Annual Conference of the European Association for Machine Translation*, pages 217–226, 2023.
- [3] Zhiwei He, Tian Liang, Wenxiang Jiao, Zhuosheng Zhang, Yujia Yang, Rui Wang, Zhaopeng Tu, Shuming Shi, and Xing Wang. Exploring human-like translation strategy with large language models. *Transactions of the Association for Computational Linguistics*, 12:229–246, 2024.
- [4] Cameron Jones and Ben Bergen. Does gpt-4 pass the turing test? In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 5183–5210, 2024.
- [5] Cameron R Jones and Benjamin K Bergen. Large language models pass the turing test. *arXiv preprint arXiv:2503.23674*, 2025.
- [6] Yafu Li, Ronghao Zhang, Zhilin Wang, Huajian Zhang, Leyang Cui, Yongjing Yin, Tong Xiao, and Yue Zhang. Lost in literalism: How supervised training shapes translationese in llms. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 12875–12894, 2025.
- [7] Martin Popel, Marketa Tomkova, Jakub Tomek, Łukasz Kaiser, Jakob Uszkoreit, Ondřej Bojar, and Zdeněk Žabokrtský. Transforming machine translation: a deep learning system reaches news translation quality comparable to human professionals. *Nature communications*, 11(1):4381, 2020.
- [8] Avraham Rahimov, Orel Zamler, and Amos Azaria. The turing test is more relevant than ever. *arXiv preprint arXiv:2505.02558*, 2025.
- [9] Ishika M Rathi, Sydney Taylor, Benjamin Bergen, and Cameron Jones. Gpt-4 is judged more human than humans in displaced and inverted turing tests. In *Proceedings of the 1st Workshop on GenAI Content Detection (GenAIDetect)*, pages 96–110, 2025.
- [10] Weiqi Wu, Hongqiu Wu, and Hai Zhao. X-turing: Towards an enhanced and efficient turing test for long-term dialogue agents. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5874–5889, 2025.