

Weekly Report June 11, 2026

張 辰強†

† 大阪大学大学院情報科学研究科

E-mail: †chenqiang.zhang@ist.osaka-u.ac.jp

今週は、実験プラットフォーム MMTT(MT-Mediated Turing Test) の実装を本番環境まで進めた。また、単なる Web 実装の報告ではなく、研究として何を測るのか、そのためにどのように条件を組み、どのようにデータを残すのかを整理した。

1. 研究質問の再定義

MMTT は、古典的な Turing Test [4] と最近のオンライン LLM 評価 [3] をもとに、会話する二者の間に機械翻訳 (MT) の層を入れた Web 実験である。参加者である Interrogator は一つのチャット画面で相手である Witness と会話する。Witness は人間の場合も AI の場合もあるが、その正体は隠される。会話後、Interrogator は相手が人間か AI かを、確信度と理由を添えて判断する。

最初の問いは「LLM の人間らしさは、MT を通ると弱くなるのか」であった。しかし、この形では結果の解釈がやや一方向的になる。そこで現在は、本研究を **cue ablation(手がかりを取り除く) 実験**として捉え直している。

人間か AI かの判定には、大きく二種類の手がかりがある。一つは、誤字、話し言葉の断片、返信のリズム、表現の癖などの**表面的なスタイルの手がかり**である。もう一つは、考え方、知識の使い方、感情の表れ方、経験の具体性などの**内容に関わる手がかり**である。このような手がかり自体は、先行研究でも議論されている [1, 2]。

本研究では、MT を前者のスタイル手がかりを弱め、後者の内容手がかりを比較的残すフィルタとして扱う。したがって中心的な問いは次のように整理できる。

人間らしさ、あるいは AI らしさという信号は、言語のどの層に書き込まれているのか。

この捉え方では、結果がどの方向に出ても解釈できる。

- MT 条件で AI が見破られにくくなる場合、AI らしさは主に表面的なスタイルにあり、MT がその手がかりを消したと解釈できる。
- MT 条件で AI が見破られやすくなる場合、LLM の人間らしさはスタイルの模倣に依存しており、翻訳後には内容レベルの弱さが残ると考えられる。
- 差がない場合、判定は主に内容の層で行われており、Turing 判定は翻訳の影響を受けにくいという方法論上の知見になる。

2. 実験条件

実験条件は、channel と prompt 強度の二軸で組む。主条件は、channel(same-language / MT) × prompt 強度 (baseline / conversational / naturalistic) の 2×3 である。これに Human Witness 条件を対照として加える。

channel 軸は、本研究の中心である「MT は見分けるための情報を壊すのか」に対応する。prompt 軸は、prompt だけの効果を見るためではない。prompt が AI の人間らしさに影響すること自体は既に知られている [3]。ここで見たいのは、**prompt によって作られた人間らしさが翻訳を通り抜けるかどうか**である。そのため、prompt 軸は channel 軸と掛け合わせて初めて意味を持つ。

事前登録する仮説は次の二つに整理できる。

H_1 (channel の主効果): MT 条件では、同一言語条件より感度 d' が下がる。

H_2 (channel × prompt の交互作用): prompt による人間らしさの向上幅 $\Delta(\text{naturalistic} - \text{baseline})$ は、MT 条件では同一言語条件より小さくなる。

H_2 が支持されれば、prompt が作る人間らしさは主に表面的なスタイルにあり、翻訳を通り抜けないと考えられる。棄却されれば、prompt は内容の層にも影響している可能性がある。

分析指標としては、正答率だけでは不十分である。MT は AI の不自然さを消すだけでなく、人間の発話も機械っぽい翻訳調 (translationese) に変える可能性がある。そのため、信号検出理論 (SDT) に基づき、感度 d' と判断基準 c を分けて報告する。 d' は見分けるための情報量を表し、 c は「AI だと思いきやす/人間だと思いきやす」という判断の偏りを表す。

3. システム実装

システムは Node.js + PostgreSQL の Web プラットフォームとして実装した。公開側の参加者は、トップページ、説明画面、条件設定、マッチング、役割確認、チャット、最終判断という流れで実験に入る。Website 自体の細かい UI は実機デモで示すため、ここでは実験デザインに関わる実装上の要点だけを述べる。

- **人間優先マッチング:** 参加者を確率的に human branch または AI branch に割り当てる。AI branch でもランダムな待ち時間を入れ、「すぐマッチしたから AI」という手がかり

りを防ぐ.human branch で相手が見つからない場合は、一定時間後に AI Witness へ切り替える。

- **同一言語条件と MT 条件:** setup 時に same-language 条件か cross-lingual 条件を選べる。どちらの場合も参加者は自分の使用言語を選び,matching logic が条件に合う相手を割り当てる。
- **AI Witness の応答制御:** AI の API 応答速度が手がかりにならないように、文字数に基づく返信遅延,debounce による連続メッセージへのまとめ返信、複数吹き出しへの分割を行う。
- **Prompt profile:** AI Witness には baseline, conversational, naturalistic の三段階の prompt 強度を用意し、各セッションに profile ID と prompt version を保存する。
- **内部ツールの分離:** AI Interrogator,Provider Console,Data Console は隠し開発者ページとして実装し、公開 UI からは見えないようにしている。

特に重要なのは,UI や待ち時間そのものが AI 判定の手がかりにならないようにする点である。本研究では会話内容と翻訳の影響を見たいので、システム側の挙動から余計な手がかりが漏れることをできるだけ避ける必要がある。

4. データ組織

データ設計は、実験条件の再現と後続分析を目的にしている。すべてのデータは主に五つのテーブルに分けて保存される。

表 1 主要テーブルと分析上重要なフィールド

テーブル	主な内容
experiment_sessions	test mode, 両者の役割と種別 (human/AI), 言語ペア, UI 言語, 翻訳・LLM provider, prompt profile, prompt version, temperature, 返信遅延設定, 制限時間, 各段階の時刻。
messages	発話ごとの記録。送信者の役割と種別, 原文の言語・原文・訳文の言語・訳文 , 翻訳処理時間, LLM 処理時間, 返信文字数, 遅延の内訳 (目標値・実処理・人工的な追加分) , 作成時刻。
judgments	最終判定。回答した正体, 実際の正体, 確信度, 自由記述理由, 翻訳の自然さスコア, 会話の流れのスコア, MT を疑ったかどうか。
provider_logs	provider 呼び出しごとの入出力, 処理時間, エラー。デバッグとモデル間比較に使う。
matchmaking_tickets	matching branch, 待ち時間設定, AI へ切り替えた時刻。待ち時間の偏りや fallback の影響を確認する。

特に messages では,Interrogator 側と Witness 側のどちらの発話についても、原文と訳文をペアで保存している。したがっ

て、同じ発話について翻訳前後の特徴量を直接比較できる。これは本研究の中心である「どの手がかりが翻訳を通り抜けるか」を分析するために必要である。

5. 分析計画

データ構造は、次の分析に対応している。

- (1) **メイン分析:** judgments の「回答した正体 × 実際の正体」から d' と c を計算し,experiment_sessions の channel と prompt profile ごとに比較する。確信度も記録しているため、補助的に ROC/AUC も使える。
- (2) **判定理由の分類:** 自由記述の理由をコードブックで分類し、どの手がかりがどの条件で使われたかを比較する。翻訳自然さスコアと MT 疑いフラグも補助指標として使う。
- (3) **テキスト特徴量分析:** messages の原文/訳文ペアを使い、文長、語彙多様性、会話の連続性、質問頻度などの特徴量が翻訳前後でどれだけ変化するかを見る。
- (4) **行動手がかりの対照:** 返信遅延の内訳を使い、テキストの層とは別に、応答速度や間隔が判定に与える影響を確認する。

データの取り出しは Data Console から行う。研究用には、ケースごとに session 情報,transcript, 全発話の原文/訳文,judgment をまとめた compact JSON を使う。デバッグ用には,provider logs を含む full raw JSON も出力できる。

6. 次の作業と確認したい点

今後の作業は以下である。

- (1) pilot 実験を行い、参加者が流れを理解できるか,UI 上の説明が十分かを確認する。
- (2) very short conversations をすぐ除外するのではなく,raw data として残した上で、後から cleaning rule を定義する。
- (3) prompt profile ごとに AI Witness の応答が過度に機械的でないかを確認する。
- (4) 判定理由を分類するための codebook を作る。
- (5) same-language 条件と MT 条件で必要なサンプル数を見積もる。

先生に確認したい点は二つある。第一に、本研究を「MT が LLM の人間らしさを弱めるか」ではなく、**MT による cue ablation** として位置づける方針でよいか。第二に、主指標を正答率ではなく SDT の d' と c に分ける分析計画でよいかである。

文 献

[1] Elizabeth Clark, Tal August, Sofia Serrano, Nikita Hduong, Suchin Gururangan, and Noah A. Smith. All that's 'human' is not gold: Evaluating human evaluation of generated text. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 7282–7296, 2021.

- [2] Maurice Jakesch, Jeffrey T. Hancock, and Mor Naaman. Human heuristics for AI-generated language are flawed. *Proceedings of the National Academy of Sciences*, 120(11):e2208839120, 2023.
- [3] Cameron Jones and Ben Bergen. Does GPT-4 pass the turing test? In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 5183–5210, 2024.
- [4] Alan M. Turing. Computing machinery and intelligence. *Mind*, 59(236):433–460, 1950.