

MMTT 週報: マッチング機構の変更と実験デザイン

張 辰強†

† 大阪大学大学院情報科学研究科
E-mail: †chenqiang.zhang@ist.osaka-u.ac.jp

1. 今週の進捗

今週は MMTT のマッチング機構を,lobby table (ロビー卓) モデルへ作り替えたうえで, さらに AI を「ロビーを流動するチケット」として確率的に運用する方式へと改良した.

2. マッチング機構の変更

2.1 出発点: 不可視な確率割当の限界

旧来は,enroll 時に確率で人間 / AI 分岐へ割り当て, ランダム待機の後 AI へフォールバックしていた (割当は参加者から不可視). 最大の制約は, 人間-人間条件が **2 名の同時オンライン**を要する点であった (AI 条件は 1 名で完結).

2.2 現行: lobby table モデル+流動する AI チケット

参加者は enroll 後ロビーに入る (既定 LOBBY_TABLES=9 卓, 各 2 席, いずれも匿名の席色で表示). 卓は人間卓・AI 卓・空卓の 3 種からなり, 参加者は見分けられない.

最大の変更点は, AI を装飾的なおとり卓ではなく, 人間と同じ lobby に着席・待機する「AI チケット」として実装したことである. AI チケットは次の性質を持つ.

- 人間と同様に**実際の待機時間**を持つ (着席時刻 lobbyJoinedAt から計算). 以前は AI 卓の待機秒数が null で, これ自体が手がかりになり得たが, 現在は人間卓と対称になった.
- 役割**を持つ: AI が証人 (自分=審問者) または審問者 (自分=証人, LOBBY_AI_INTERROGATOR_RATE= 0.35) .
- TTL** (LOBBY_AI_TTL_SECONDS= 120 秒+ jitter) で lobby から退出する → AI も人間のように**出入りする (流動する)**

AI チケットの**確率的フロー**は, 活性 AI チケット数を目標レンジ (MIN= 2, MAX= 6) に保つよう制御される. 下限を割れば補充し, レンジ内ではスポン間隔タイマーと参入確率 (LOBBY_AI_ENTRY_PROBABILITY= 0.45) に従って確率的に出現する. これにより, AI の到着が人間の自然な出入りを模倣する. 加えて AI は受動的に待つだけでなく, **一定時間待った人間卓へ AI 側から能動的に相席することもある**.

マッチング契機は二つ: 同一卓に 2 名が揃えば人-人 session, 着席後 LOBBY_AI_FILL_SECONDS= 45 秒で相手が来なければ AI フォールバック. 同端末 fingerprint による自己マッチング防止は維持している.

表 1 主な lobby 設定 (MATCHMAKING_LOBBY_*)

変数	既定 / 役割
TABLES	9 (ロビーの卓数)
AI_TABLES_MIN / MAX	2 / 6 (活性 AI チケットの目標レンジ)
AI_ENTRY_PROBABILITY	0.45 (レンジ内での確率的出現)
AI_SPAWN_INTERVAL_SECONDS	出現間隔 (+ jitter)
AI_TTL_SECONDS	120 (+ jitter); AI の退出
AI_INTERROGATOR_RATE	0.35 (AI が審問者になる割合)
AI_FILL_SECONDS	45 (着席後の AI フォールバック)

2.3 利点: ボトルネックと手がかり漏洩の同時解消

- 人-人マッチングのボトルネック解消**: 要件を「全員が同時オンライン」から「審問者が来たとき相手が着席している」へ弱めた. ロビーが持続的な会合点として働き, 先着が着席して待ち, 後着は相席できるため, 同時刻の一致が不要になる.
- 基率 (base rate) 漏洩の防止**: 流動する AI チケットにより, **実人数が少ない時間帯でもロビーが自然に賑わって見える**. これにより「人が少ない=相手は AI だろう」という推測を防ぐ. 以前指摘した手がかり漏洩への中心的対策である.
- 待機表示の対称化**: AI チケットが人間と対称な待機時間を持ち, 確率的に出入りするため, 待機秒数や出現タイミングから AI を見分けることが困難になった.

2.4 今後の改善: 人数に応じた適応的フロー

有償募集のため, 人間ユーザーのアクセスは波状 (バースト的) になると予想される. **人が多い時間帯には人-人試行を, 少ない時間帯には人-AI 試行を多く成立させたい**. 現行モデルでも, 人-人マッチングが 45 秒のフォールバックと競合するため, この傾向は**創発的には生じる**. ただし在線人数を明示的に観測しておらず, 混雑時には AI の能動的な相席が人-人の機会を奪うため, 保証はされない. 今後は**待機中の人間数に応じて AI フロー (spawn・能動的相席・fill タイムアウト) を適**

応させ、混雑時は AI を抑制して人-人を優先し、閑散時は AI を増やす方針とする。これに伴い実現基率は時間帯で変動するため、session ごとに記録し共変量化する。

3. 実験デザインへの影響と論点

- (1) **self-selection (自己選択)** : 参加者が卓を能動的に選ぶため、条件 (人間 / AI) への割当が**非ランダム**になりうる。選卓行動が疑い・戦略と相関するとセル割当が被験者特性と交絡し、 d' の解釈を損なう。対策は、(a) 見かけ上は自由選択でも裏側で quota により分配を制御する、または (b) 選択を記録し共変量として統制する。
- (2) **手がかり漏洩は大幅に改善** : AI が対称な待機時間を持ち流動するため、以前の `waitingSeconds=null` 由来の手がかりは解消した。残る点検項目は、**スポーン間隔・TTL の分布が人間の到着・滞在分布と整合するか**、および AI の相席挙動の対称性である。
- (3) **基率が創発的 (emergent)** : AI と人間の遭遇比は、フロー parameters (目標レンジ・参入確率・TTL) と実際の人間流量との相互作用で決まり、単一の確率では制御しきれない。**実現基率**を session ごとに記録し共変量化化する必要がある。条件別に基率を揃えたい場合は、フロー parameters を条件ごとに調整する。
- (4) **AI-interrogator session の位置づけ** : AI が審問者・人間が証人となる session (割合 0.35) では人間は判定を産まない (判定は AI 側)。これは主分析の 2×2 (人間審問者が判定) の外にある。人間証人データの採集として用いるか、inverted TT 的拡張とするかを明確化し、主分析に入れるか決める。

4. 実験デザイン (現状)

本実験は、古典的チューリングテスト [4] と近年の交互式 LLM 評価 [2] を拡張し、二者間に機械翻訳 (MT) 層を挿入する。研究を「LLM が (言語横断) TT を通過するか」という弱い方向性予測ではなく、**cue ablation (手がかり切除) 実験**として捉え直す：中心の問いは「人間らしさという信号は言語のどの層に書き込まれているのか」である。

- **要因** : channel (same-language / MT 中介) $\times$ prompt 強度 (baseline / naturalistic) の 2×2 、人間 Witness の対照を加える。
- **従属変数** : Interrogator の「人間 / AI」二択判定。正答率は感度と偏りを混同するため、信号検出理論 (SDT) [1,3] の二指標で報告する：感度 d' と判断基準 c 。
- **仮説** : H_1 (channel 主効果) MT 下で d' 低下 ; H_2 (channel $\times$ prompt 交互作用) 擬人化利得 $\Delta(\text{naturalistic} - \text{baseline})$ が MT 下で縮小。

- **規模** : 被験者内 (繰り返し測定) 設計により人数を約 50~80 名に圧縮。言語ペアは 1 対 (ja $\leftrightarrow$ en 推奨) に限定。翻訳モデル・AI モデルは固定し、翻訳品質は共変量として測定する。

prompt 強度は AI Witness にのみ作用し、人間 Witness 試行は各 channel 内で false alarm 基準を与えて prompt 水準間で共有される。条件セルは次の通りで、各 channel $\cdot$ prompt 水準について $d' = z(\text{hit rate}) - z(\text{false alarm rate})$ を計算する (hit rate は対応する AI セル、false alarm rate は同 channel の人間 Witness セルから得る)。

表 2 条件セルの構成 (d' 算出の単位)

Witness	same-language	cross-lingual (MT)
AI $\cdot$ baseline	セル	セル
AI $\cdot$ naturalistic	セル	セル
Human (対照)	FA 基準	FA 基準

確認的因子は baseline と naturalistic の 2 水準とし、AI セルは 4 個 (2 channel $\times$ 2 prompt)、人間セルは 2 個、計 6 セルとなる。

今回のマッチング変更は、このうち主に**条件割当の方法** (self-selection vs quota, 創発的基率の記録) と**人-人データの採集運用**に関わる。

5. 来週の予定・確認事項

- (1) AI フローの人数適応化を実装する：待機中の人間数に応じて、混雑時は人-人を優先 (AI 抑制)、閑散時は人-AI を増やす。
- (2) ロビーの対称性点検 : AI チケットのスポーン間隔・TTL・相席挙動が人間の分布と整合するかを検証し、必要なら調整する。
- (3) 創発的基率を session ごとに記録する仕組みを整え、共変量として解析に組み込む。
- (4) self-selection の扱いを決める：裏側 quota 制御か、選択の共変量化か。
- (5) AI-interrogator session のデータ上の役割を確定し、主分析に含めるか判断する。
- (6) `.env.example` を新しい `MATCHMAKING_LOBBY_*` 変数に同期する (現状は旧確率変数のまま)。

文 献

- [1] David M. Green and John A. Swets. *Signal Detection Theory and Psychophysics*. Wiley, New York, 1966.
- [2] Cameron R. Jones and Benjamin K. Bergen. Large language models pass the turing test. *arXiv preprint arXiv:2503.23674*, 2025.
- [3] Neil A. Macmillan and C. Douglas Creelman. *Detection*

Theory: A User's Guide. Lawrence Erlbaum Associates, 2nd edition, 2005.

- [4] Alan M. Turing. Computing machinery and intelligence. *Mind*, 59(236):433–460, 1950.