

MMTT 週報: 人間らしさの改善と計時・言語条件の修正

張 辰強†

† 大阪大学大学院情報科学研究科

E-mail: †chenqiang.zhang@ist.osaka-u.ac.jp

1. これまでの主な変更

- (1) **対話時間の短縮と UI 整理**: ラウンドを短く・左右対称にし, 判定フォームをチャット画面の横に置いた。
- (2) **双方が判定**: 判定をチャット内に入れ, 人どうしの時は両者が相手を判定する。
- (3) **プロンプト改修 (3+10)**: 3 つの profile(baseline / conversational / naturalistic) を用意し, naturalistic には 10 種類の人物設定を持たせた。baseline は最小限にし, 身分を聞かれても話をそらす。
- (4) **マッチング改修 (hidden dynamic)**: 卓を選ばせる方式をやめ, 「言語が同じか違うか」「相手が AI か人か」をシステムが裏で自動的に決める。AI になる確率は待ち状況に応じて変わる。

2. 今週の追加変更 (06-25~06-29)

方針は「人間らしさは細かい命令ではなく, ゆるい人物設定とサンプリングで出す」「出力を後から書き換える仕掛けは逆効果」で一貫している。

- (1) **プロンプトを人間らしく (naturalistic v5→v7)**
 - 命令の列挙をやめ, ゆるい人物設定に (v5): 安全のルールだけ残し, 出力の後処理は全部やめた。同じ返事の繰り返しは, 温度と反復ペナルティ(chat 系のみ) で抑える。
 - 返事を短く: max_output_tokens を 500→200 に。
 - 頼まれても代わりに作業しない (v6): 「書いて/翻訳して/コードを」に, 普通の人のように受け流す。
 - 詳しくすぎない (v7): 専門的な話題は素人として答える。妙に詳しいと AI だとバレる。
- (2) **返事までの「間」を調整**: 打つ速さ(文字数)に加え, 相手の文の長さ(読む時間)と, ばらつきのある考える時間を足した。
- (3) **計時の開始タイミングを修正**: 以前は会話作成時や参加時に時間が始まり, 説明を読む間に減っていた。必要な人が全員「説明を確認」してから始まるように変更。AI witness は AI 側が自動で準備完了なので, 人が確認すればすぐ始まる。片方だけ確認のまま 90 秒経つと終了。

- (4) **言語条件の均衡**: 同言語か異言語かを毎回コインで決める方式から, 最近の分を見て半々になるよう配る方式に変えた。
- (5) **データ画面の整理**: 期間で絞る機能, 古い conversational を既定で除外, 生データの表は外してエクスポートに任せる, 内部コンソールから導線を追加。

3. 直近 5 日間のデータ (06-24~06-29)

本番 DB から直近 5 日間の公開セッションを集計した(内部テストは除く)。均衡化や強化は期間の後半に入れたので, その効果が出たデータはまだ少ない。

表 1 直近 5 日間の収集データ

項目	値
公開セッション数	31 (AI Witness 21 / 人間 Witness 10)
言語条件	異言語 23 / 同言語 8
AI の profile	baseline 10 / naturalistic 11 (古いものなし)
状態	completed 21 / ready_for_judgment 10
判定数	21 件
メッセージ数	389

表 2 言語条件ごとの判定

言語条件	AI を AI/人間と判定	見破り率	人間証人 n(誤検出)
異言語	11 / 0	100%	2 (0%)
同言語	5 / 3	62.5%	0 (データなし)

表 3 prompt ごとの判定 (AI が判定された件数)

profile	AI/人間と判定	通過率 (人間と誤認)
baseline	7 / 1	12.5%
naturalistic	9 / 2	18.2%

4. 所 見

- **通過の兆し:**AI が「人間」と間違われたのは同言語で 3/8(37.5%)。6/25 の「全部バレ」から少し良くなった。
- **逆向きの傾向 (数が少ない, 注意):** 同言語では 37.5% 通過だが, **異言語は 0/11(全部バレ)**。翻訳を通すと AI がかえってバレやすいのかもしれない (翻訳調が手がかりになる?)。ただし数が少なく他の要因も混ざるので, まだ断定できない。これは H1(言語条件の効果) の予備的な方向。
- **prompt の弱い兆し:**naturalistic 18.2% ̳ baseline 12.5%。効いているかもしれないが数が少ない。割り当ては baseline 10 / naturalistic 11 でほぼ半々で, 2 つの条件は独立に決まる (交互作用も推定できる)。
- **一番の課題は FA データ不足:** 人間 witness の判定が異言語 2 件・同言語 0 件しかない。 d' には各条件で hit と FA(人間を AI と間違える率) の両方が要るので, 今はほぼ計算できない。**人間 witness を増やすのが最優先** (人がいれば人どうしを優先するようにした)。
- **言語条件の偏り:** 異言語 23 / 同言語 8。均衡化は 06-28 からで, この 5 日間の多くはそれ以前。今後は半々に近づく見込み。
- **データ品質:** この期間に古い conversational は入っていない。

5. 次の一手

- (1) v6/v7 以降のデータを取り直し, baseline と naturalistic の通過率の差を見る。
- (2) 均衡化のあと, 同言語/異言語が実際に半々へ近づくか確認する。
- (3) 人間 witness を増やし, 各条件の FA を取る (d' に必要)。
- (4) **要確認: 同言語の文体弱化。** 同言語は原文をそのまま出すため, 異言語との差に「翻訳の有無」だけでなく「書き換えの有無」も混ざる。同言語側にも書き換えを挟むか (A: そのまま / B: 同言語で書き換え / C: 異言語の翻訳) を Phase 2 前に決める。