

Weekly Report

張 辰強†

† 大阪大学大学院情報科学研究科

E-mail: †chenqiang.zhang@ist.osaka-u.ac.jp

1. 研究課題 (RQ) の再確認

これまで (発表スライド) では, 研究課題を次の 2 つで示していた。

- How does MT change human discrimination?(機械翻訳は, 人が相手を見分ける力をどう変えるか)
- Does prompt-humanness survive MT?(prompt で作った人間らしさは, MT を通しても残るか)

今回, この 2 つをまとめた, より大きな問いとして, 次のように言い換えたい。

Prompt で作った人間らしさという信号は, 言語のどの層に書き込まれているのか。

ねらいはこうだ。「人間らしさ」を, 言葉の見た目 (語彙・文法・言い回し) にあるものと, 意味・内容にあるものに分けて考える。MT は見た目をほぼ入れ替えるが, 意味は残す「フィルタ」のようなものだ。だから「MT を通しても人間らしさが残るか」を測れば, 人間らしさが言葉のどの層にあるのかを見分けられる。この大きな問いのもとで, 従来の 2 つは次の 2 つの仮説として測る。

- **H1:** 言語条件 (同言語/異言語 = MT が入るかどうかが, 相手を見分ける正確さ d' にどう効くか。
- **H2(中心):** prompt で作った人間らしさが MT を通しても残るか, つまり言語条件 × prompt の相互作用。ここが本研究のいちばん新しい点である。

2. 初期データで分かった問題

(1) 人どうし (H-H) がほとんど組めなかった。

約 10 名が同時につないだ予備実験で, H-H が組めたのは 21 回中 2 回ほどだった。主な原因は次の 2 つと考える。

- (1) **異言語にするかを参加者が選べた:** 当時は「異言語で行うか」を自分で選べて, **ほぼ全員が異言語を選んだ**。そのため同言語の H-H が生まれにくかった。
- (2) **参加者がほぼ日本語話者だった:** 異言語のペアも作りにくく, 結局その多くが AI と当たった。

対策として, 言語条件は自分で選ぶのをやめ, システムが割り当てる方式にした。さらに, 人が十分いれば H-H を優先する (後述)。ただし**参加者の言語のかたよりは**, 運用上の課題として残る。

(2) AI がすぐ見破られやすかった理由。

いちばんの原因は, **2 種類の prompt を混ぜて使っていること**だと考える。baseline はわざと最小限の設定にしてあり, **もともと見破られやすい** (比較の「下限」として置いている)。実際, 先週のデータでも通過率は baseline 12.5% < naturalistic 18.2% だった。「AI がよくバレる」と感じるのは, 一部はこの弱い baseline を混ぜているためでもある。評価するときは, baseline と naturalistic を分けて見る必要がある。

3. システム改修のまとめ

作業の順番ではなく, 最終的に決まった状態だけをまとめる。

- (1) **対象を 3 言語にしぼった:** 日本語・英語・中国語だけを使えるようにし, それ以外の言語は選択・マッチング・AI bot のどこでも使えないようにした (戻すのはフラグ 1 つで可能)。
- (2) **判定は片方だけに戻した:** 判定するのは interrogator のみ。AI witness も終了時に内部で判定するが, **画面には出さず, 記録用のデータとしてだけ残す**。公開の AI interrogator はやめ, 内部の開発用画面だけ残した。
- (3) **マッチングを自動にした:** 卓を選ばせる方式をやめ, システムが裏で割り当てる。人を探す確率は一定 ($p = 0.85$) にし, 実際の人/AI の割合はその時の混み具合で自然に決まる。あわせて, 待っている 2 人を組ませる・足りない条件を先に埋める・一定時間で打ち切る・マッチの速さから AI と気づかれないよう待ち時間を調整する, を使う。人がいれば H-H を優先する。
- (4) **prompt: baseline(最小) + naturalistic(ゆるい人物設定 v8, 10 人格)。** 出力を後から書き換える処理はやめ, 同じ返事の繰り返しは生成時の設定 (ペナルティ) で抑える。返事は短く, 専門的な話題は素人として答え, 同じ質問を繰り返されたら人間らしく反応する。
- (5) **計時の開始を直した:** 両方が「説明を確認」してから時間を数え始める。3 分たてば, 途中でも判定して早く終われる。

- (6) **言語条件を半々に:** 同言語/異言語を毎回コインで決めるのをやめ, 最近の分を見て半々に近づくよう配る。
- (7) **同意とプライバシーを明示:** 同意説明文書 (インフォームド・コンセント) を読めるようにし, 相手の個人情報は聞かないこと, 会話が研究に使われることを, はっきり示した。
- (8) **はじめての人向けの説明:** トップページに, チューリングテスト/MMTT の枠組み (MT を通したチューリングテスト) と遊び方をのせ, 仕組みが一目で分かるようにした。
- (9) **同言語に「往復翻訳」の枝を追加:** 同言語セッションの半分を, 母語 → 別の言語 → 母語 と往復させる「文体フィルタ」に通すようにした (残り半分はそのまま)。これで通道が **A: そのまま同言語 / B: 往復同言語 / C: 異言語** の 3 枝になり, 第 1 段階のデータで同時に比べられる (枢軸言語は原則 English, 半々に配分, セッションに記録)。

4. まだ決めていないこと

- (1) **同言語の「往復翻訳」枝 (実装済み)——最終的にどう扱うか。**

同言語では原文をそのまま見せるため, 異言語との違いに「翻訳するかどうか」だけでなく「**文が書き換わるかどうか**」も混ざる。そこで同言語セッションの半分を往復翻訳 (A: そのまま / B: 往復同言語 / C: 異言語) に通す枝を**実装し, 第 1 段階で A・B・C を同時に検証**することにした。残る判断:(i) 本分析で 3 枝のまま扱うか, 効果が小さければ A と B をまとめるか。(ii) 枢軸言語 (現状 English) や往復による二重翻訳ノイズの影響。(iii)**3 枝に分けても各セルのサンプル数が足りるか** (データ不足が最大の制約なので, ここは要監視)。
- (2) **「AI-Interrogator」をやめたことで, 人の少なさが見えちゃう心配。**

以前は AI interrogator が卓を埋めていて, 同時につないでいる人が少ないことを隠す働きもあった。やめたことで, witness になった人に相手 (interrogator) がつかない・ロビーが空に見える, など**人が少ないことが表に出やすくなる**心配がある。今は AI witness への切り替えと待ち時間の調整でやわらげているが, 実際の運用で様子を見る必要がある。
- (3) **「相手の言語 (翻訳の有無)」の表示を消したことで, 新しい問題が出ないか。**

ねらいは**言語から来るヒントを消す**ことである (「異言語だ」と分かること自体が, 見分けるヒントになってしまう)。一方で, 参加者が状況を勘違いする, 翻訳のせいの不自然さを「**相手が変わった**」と思ってしまう, といった副作用の心配がある。要検討。